Welcome

MSRA Researcher新手，现阶段从事多模态大模型预训练方向。对NLP感兴趣或对博客内容有疑惑及意见建议的，欢迎评论或添加我微信。此外如果有需要内推的同学，也欢迎来骚扰我。联系方式详见concat页面。

前往GitHub (https://github.com/Dod-o)

论文阅读|How Does Batch Normalizetion Help Optimization

5月 23, 2019 (http://www.pkudodo.com/2019/05/)

论文阅读|How Does Batch Normalizetion Help Optimization

作者 Dodo (http://www.pkudodo.com/author/root/) 在 (http://www.pkudodo.com/2019/05/23/1-11/)
未分类 (http://www.pkudodo.com/category/uncategorized/)

前言

Batch Normalization在2015年被谷歌提出，因为能够加速训练及减少学习率的敏感度而被广泛使用。

但论文中对Batch Norm工作原理的解释在2018年被MIT的研究人员推翻，虽然这篇论文在2018年就已经提出了，但是我相信还有很多人和我一样，在网上看相关博客及paper时，大部分内容还是论文提出前写下的。

现在DL逐渐变成了实验科学，一般在发现性能上的提升后去分析其产生的原因，但这片论文的思想很好，从数据、公式等一系列角度去推理，分析出来了为什么batch Normalization能work。

论文地址：https://arxiv.org/pdf/1805.11604.pdf (https://arxiv.org/pdf/1805.11604.pdf)

batch Normalization的提出

抛开Norm，我们在做特征工程时，经常会将输入进行归一化，否则如果某个特征数特别大（比如说一个特征是0-1，一个特征是0-1000），那第二个特征很有可能会对整个模型参数造成很大的影响。或者说，当训练集数据的分布不一致时，例如前一个输入的各特征范围是0-1，后一个是0-100，网络的训练效果也不会很好。

所以，就像很多人说的一样，我们希望在deep learn中，整个网络中流过的数据都是独立同分布的。

为什么需要独立同分布?

我觉得这事可以从两方面去解释，

一方面我们希望对训练集进行训练后，在测试集上能够发挥很好的性能。那么我们就需要保证训练集和测试集是来自同一个空间，准确来说，是符合同一分布，这对同分布提出了要求。此外，在虽然数据来自同一个空间，但我们并不希望所有数据都聚集在空间中的某一小撮，而是希望所有数据对于整个空间来说都具有一定代表性，因此在采样的过程中我们希望是独立得去采样所有的数据。

另一方面，其实是从另一个角度来阐述上一段话，如果数据之间不是同分布的，比如说样本1所有的特征都处于0-1之间，样本2处于10-100，那么网络的参数其实很难去同时迎合两类分布的数据。

batch Normalization做了什么?

上面讲到了数据在最初进来的时候，都希望是独立同分布的。但是batch Normalization的作者觉得不够，应该在deep learning中的每层都进行一次处理，保证在每层都是同分布。

他是这么想的：假设网络有n层，网络正在训练，还没有收敛。这时候x1被输入，经过了第一层，但是第一层还没有学到正确的weight，所以经过weight的矩阵乘法后，第二层的数会不会很乱？会不会第二层有些节点值是个位数，有些节点值蹦到好几百？细想一下，确实挺有可能啊，内部的参数都是随机初始化的，那蹦啥结果确实不好说啊。然后恐怖的事情来了，第二层这些乱蹦的数，又输到了第三层，那第三层的输入就是乱蹦的数，输出当然好不了，以此类推。

所以主要产生了两个问题：

1.所以在前面的网络没有收敛的时候，后面的网络其实并学不到什么。一栋大楼底部都是晃的，那上面也好不了。所以必须要等前面的层收敛后，后面层的训练才有效果。

2.因为一般来说网络内部每层都需要加一层激活来增加非线性化嘛，那么如果值比较大，它通过激活以后在S曲线上会比较接近0或1，梯度很小，收敛会很慢。

所以batch Normalization就想在每层都加一个norm进行标准化，让每层的数分布相同，变成均值0，方差1的标准分布。高斯分布的标准化公式就是下面式子中括号内的部分。值减去均值再除以方差，能够得到均值为0，方差为1的标准正态分布。至于γ和β，是需要学习的两个参数，γ对数据的方差再进行一个缩放，β对数据的均值产生一个偏移。

$$BN(y_j)^{(b)} = \gamma \cdot \left(\frac{y_j^{(b)} - \mu(y_j)}{\sigma(y_j)} \right) + \beta$$

(http://www.pkudodo.com/wp-content/uploads/2019/05/batch-normalization.png)

为什么归一化成均值0，方差1后，还要再修改方差和均值？那归一化还有意义吗?

这是因为我们并不能保证这层网络学到的特征是什么，如果简单的归一化，很有可能会被破坏。比如说S型激活函数，如果这层学到的特征在S的顶端那块，那么我们做归一化以后，强行把特征带到了S的中间位置，特征就被破坏了。要注意γ和β是被训练的参数，且每层都不一样，所以针对每一层的实际情况，它会去尝试恢复这层网络所学到的特征。

结果

使用VGG网路，CIFAR10数据集（下图），可以看到与不加相比：

1.训练前期的准确率要高，也就是收敛更快。

2.减少对learning rate的敏感度，图二在lr=0.5时，不加norm的网络直接震荡了，但加nrom的仍然表现良好。

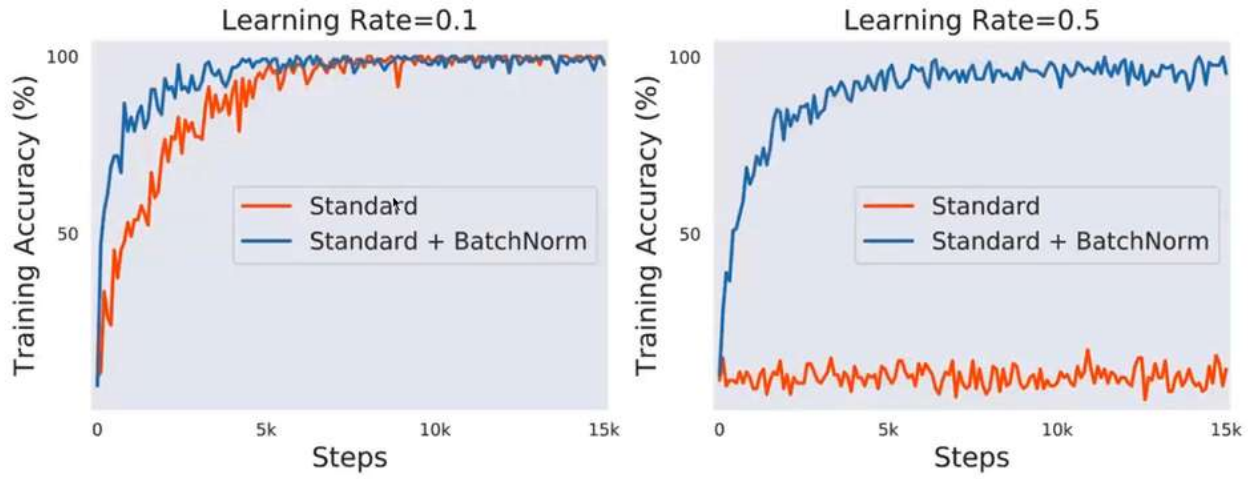

(http://www.pkudodo.com/wp-content/uploads/2019/05/batch-normalization性能.png)

所以batch normalization其实原理不是很高深，只是在每层都加了一个标准化，使得数据同分布，再对其方差和均值进行一个变换以恢复该层捕捉到的特征。最后产生了两大改变，首先收敛更快，其次对lr的敏感度降低。

那网络内每层进行一个归一化，为啥这么简单的一个思想，一直没有被运用呢？是researcher想不到吗?

我相信有很多researcher都尝试过将各层都重新标准化，但我相信最后的效果一定不太好，因为很多特征重新修改为均值0方差1后，特征的信息会被丢失。所以作者理论的突破性在归一化以后又使用γ和β重新将数据的分布进行了一个修改，以此来找回丢失的特征，当然了，只要让这两个参数能够自学习就可以了。

————————————————分割线————————————————

其实现在大部分博客沿用的解释，都是上面这种。包括我之前一直也认为是这样。

但是《How Does Batch Normalizetion Help Optimization》这篇论文认为，使用norm后的网络收敛更快，lr敏感度更低是对的，但不是因为论文里说的这种原因，而是因为每层的标准化使得最后的loss函数变成了一个光滑的曲面而造成的最后性能提优。下面来阐述一下思想：

(http://www.pkudodo.com/wp-content/uploads/2019/05/MIT三种网络比较.png)

batch Normalization 解释的反驳

实验测试

MIT的研究人员并没有在论文的一开始就提出了自己的解释。而是说，如果原作者说的是对的，那我们就先按照原作者的思路去验证一下（因为涉及两篇paper，所以本文将batch normalization的提出者写为原作者，How Does Batch Normalizetion Help Optimization的作者写为来自MIT的研究人员）：

1.原作者认为是因为网络中各层都标准化后使得分布相同，因此造成的性能提优。

来自MIT的研究人员做了三个实验作为对比：不适使用norm的普通网络、使用nrom的普通网络及添加噪音的Norm网络。

Norm网络添加噪音是考虑到原作者认为是同分布造成的性能提优。那么来自MIT的研究人员就在Norm网络的基础上，给各层再手动添加噪音，这样使得第三个网络虽然使用了norm，但每层的分布已经被打乱，不再满足同分布的情况。

下图中的实验结果表明，即使nrom网络添加了噪音，但性能仍然和添加norm的网络差不多。

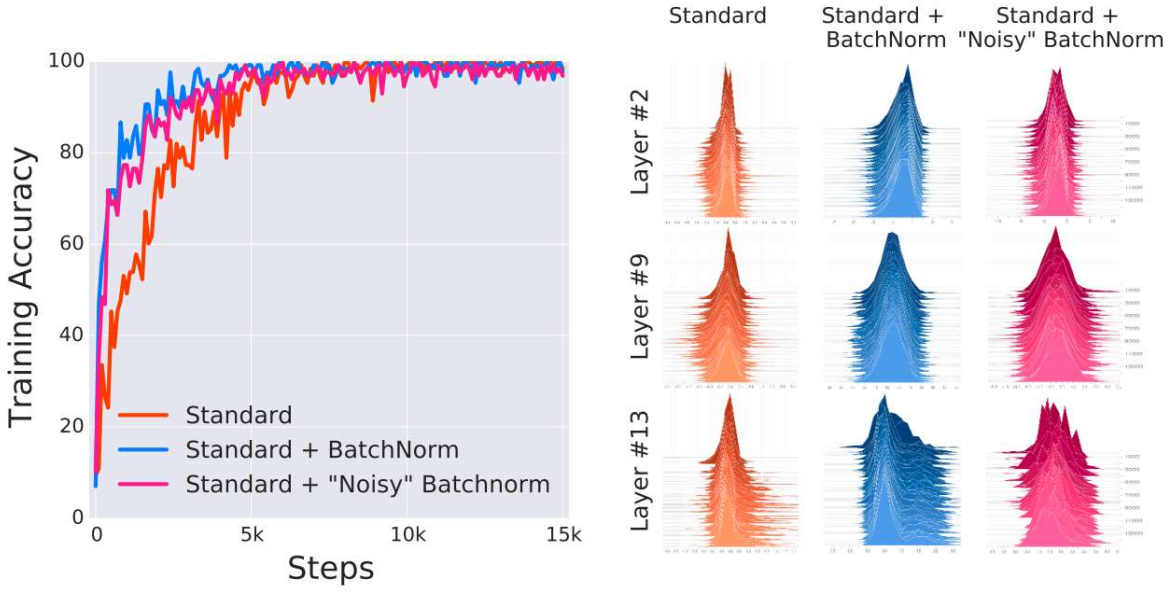

(http://www.pkudodo.com/wp-content/uploads/2019/05/MIT三种网络比较.png)

(http://www.pkudodo.com/wp-content/uploads/2019/05/loss图像.jpg)

那么最后造成性能提升的原因，肯定不是数据同分布这一解释，也就是说原作者给出的解释是错的，一定有其他的原因。

batch Normalization新解释的直观理解

在基础的学习中，我们都知道在设计loss的时候希望loss函数是光滑的，这样我们可以很顺利地使用梯度下降来更新参数并找到一个较优点。但很多时候loss并不是我们想象中的那么美好。比如说下图，左边和右边都是loss函数，但是左边的loss虽然连续，但并不光滑。在梯度下降过程中很难保证下降的有效性和快速性，此外也很容易陷入局部最优解。而右边的图虽然在四个顶点出也有局部最优解，但总体上来说还是非常理想的一个loss。

MIT的研究人员认为batch normalization的有效性在于它将左边的原始loss转变成了右边的loss，造成了上文提到的两种结果：

1.收敛速度变。

2.对学习率的设置不再那么敏感。

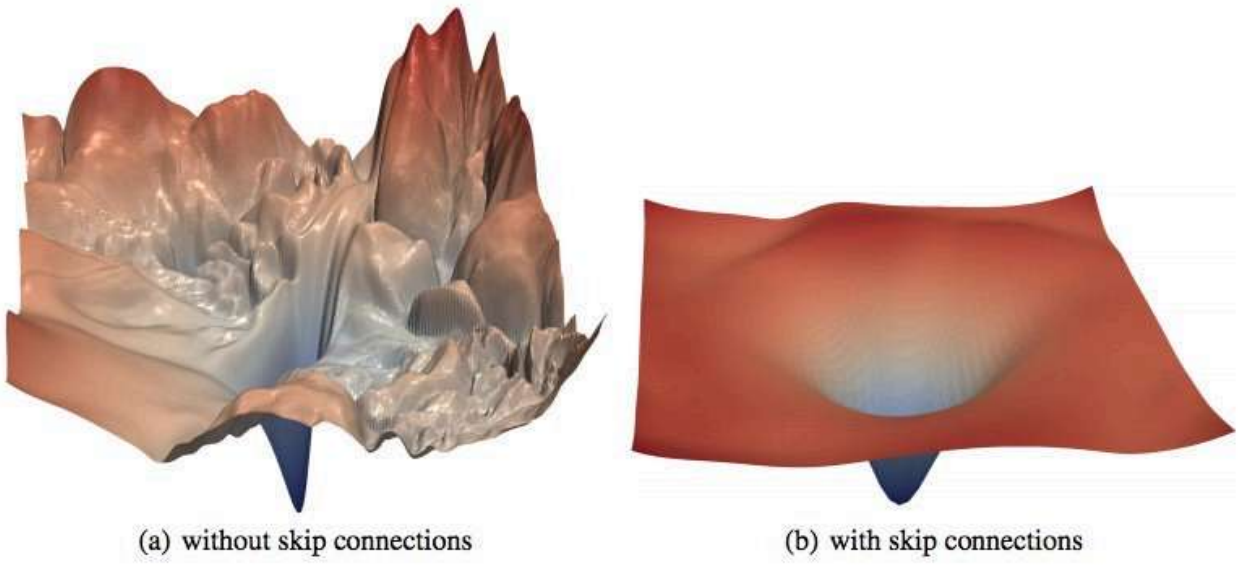

Figure 1: The loss surfaces of ResNet-56 with/without skip connections. The vertical axis is logarithmic to show dynamic range. The proposed filter normalization scheme is used to enable comparisons of sharpness/flatness between the two figures.

(http://www.pkudodo.com/wp-content/uploads/2019/05/loss图像.jpg)

分析

MIT的研究员定义了两个函数：

第一个是loss的值的计算，就是下面第一个公式，内部的loss是当前的loss，随后对loss求导，再乘以学习率，x是内部的参数，对参数进行一个更新，随后将新参数放入loss函数中，计算当前loss的值。别看这个公式看起来有点绕，实际上就是求当前的loss值。

第二个公式是计算loss的梯度差，也可以看成loss的二次求导吧（我感觉）。

1. Variation of the value of the loss:

$$\mathcal{L}(x+\eta\nabla\mathcal{L}(x)), \qquad \eta \in [0.05, 0.4].$$

2. Gradient predictiveness, i.e., the change of the loss gradient:

$$||\nabla\mathcal{L}(x) - \nabla\mathcal{L}(x+\eta\nabla\mathcal{L}(x))||, \qquad \eta \in [0.05, 0.4].$$

(http://www.pkudodo.com/wp-content/uploads/2019/05/两个值.png)

论文中之所以提出这两个公式，是为了得到两个量。

第一个公式可以得到训练过程中的loss，那么把每一个step的loss都拿出来绘制成一条曲线，该曲线可以认为是loss的波动情况。我认为如果一个loss函数本身是比较光滑的，那么第一个公式求出来的loss值并不会有一个比较大的浮动。

第二个量是计算loss的梯度差，它可以认为山坡在沿着下降的方向走时，方向改变是否会较大。也就是说，一个比较好的loss函数，在每一个step中，loss所得到的梯度应该是不会浮动太大的。就好像从山上往下走，我们向下的方向一般都不会在瞬间改变太大，而不是说往下平滑地走着走着（loss梯度稳定），突然前面是个悬崖（loss梯度骤变），而应该是有个台阶（loss梯度平滑改变）。

MIT研究人员将使用norm和普通的网络对这两个量进行了对比：

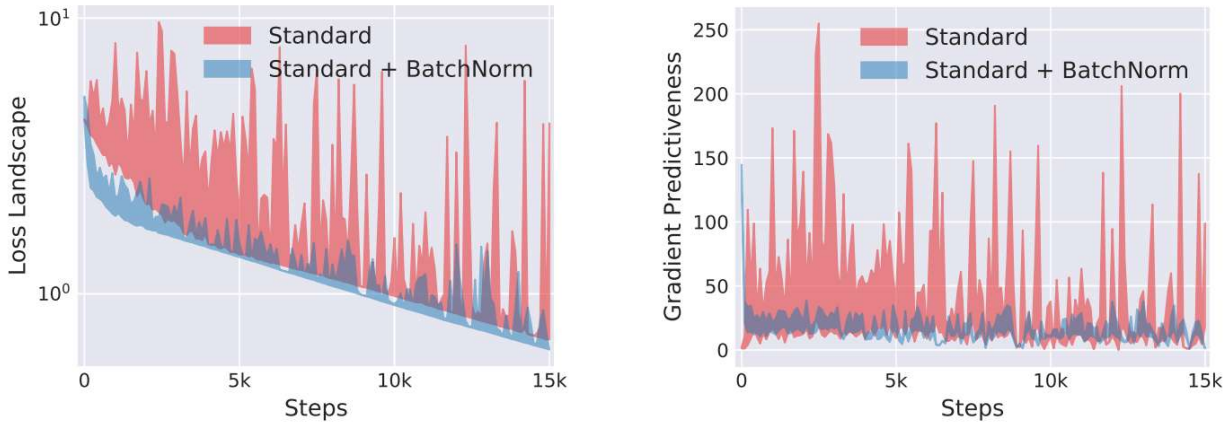

(http://www.pkudodo.com/wp-content/uploads/2019/05/loss.png)可以看到不使用norm的网络（红色），loss的梯度差浮动均较大。而使用了norm的网络（蓝色）浮动很小。也就从侧面印证了普通网络的loss比较趋向于左图。而使用了norm的，loss趋向右图。

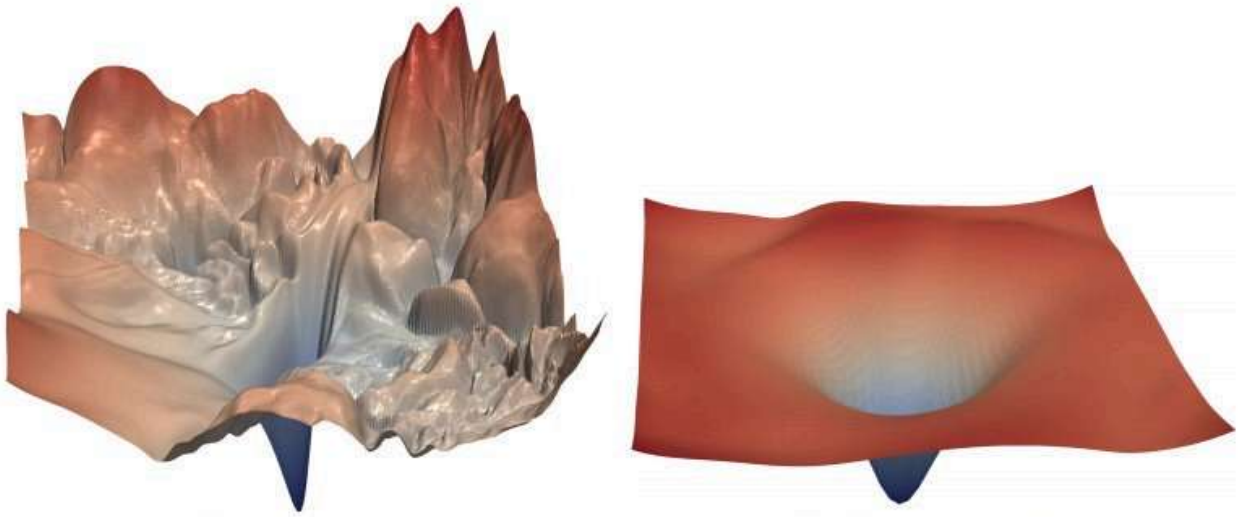

(a) without skip connections (b) with skip connections

Figure 1: The loss surfaces of ResNet-56 with/without skip connections. The vertical axis is logarithmic to show dynamic range. The proposed filter normalization scheme is used to enable comparisons of sharpness/flatness between the two figures.

(http://www.pkudodo.com/wp-content/uploads/2019/05/loss图像.jpg)

上面这两个公式其实就是整篇论文的核心，MIT的研究人烟也正是基于这两个量从而对原文进行了反驳。

1.在论文中使用了L-Lipschitz常数来定量loss的光滑程度（也就是公式1干的事），限制了loss的光滑程度，（以下定义来自百度百科）

> L-Lipschitz：直觉上，利普希茨连续函数限制了函数改变的速度，符合利普希茨条件的函数的斜率，必小于一个称为利普希茨常数的实数（该常数依函数而定）。
> 对于在实数集的子集的函数
> 
> ，若存在常数K，使得
> 
> ，则称 f 符合利普希茨条件，对于 f 最小的常数 K 称为 f 的利普希茨常数。

我个人觉得就是换了种说法，就是限制loss的一阶导数要小于常数k。一阶导数在曲线上表现的是斜率必须小于一个值，也就是说斜率不能过大。在这一条件的限制下，loss的面哪怕下降，也是很缓的。

2.论文使用了另一个更强的光滑条件来限制：β-smoothness（也就是公式2干的事）。

β-smoothness限制了就是loss斜率的斜率（可以简单看成斜率差）不能超过一定值。

$$\| \nabla f(x_1) - \nabla f(x_2) \| \leq \beta \| x_1 - x_2 \|$$

(http://www.pkudodo.com/wp-content/uploads/2019/05/Smoothness.png)

我认为这本质上其实就是二阶求导。对二阶求导后的结果进行了一个限制，使得函数在二阶条件下仍然是一个较为平滑、不会大幅度突变的函数。

也正是因为使用了batch norm的网络，它的loss从原先的原始凹凸不平状态变成了一个能满足L-Lipschitz及β-smoothness两个强条件的原因，使得bath norm能够work。

总结：原作者提出了batch norm，并造成了两个结果：1.收敛更快。2.对learning rate的敏感度更低（也就是说lr的设置是否合理不会很大程度地影响最终结果）。并且认为网络中每层都进行了一次同分布，是造成结果的主要原因。

MIT研究员根据这一思路，将使用norm的网络随机添加高斯噪声，使得网络在添加了norm的同时又去除了norm所带来的同分布效果，但结果显示优势仍然存在，因此对原作者的解释进行了反驳。

随后MIT研究人员使用了loss的一阶信息和二阶信息进行了评估，发现使用了norm以后的loss在一阶和二阶上都具有很好的性质，由此推断nrom之所以能产生效果，不是原作者提出的解释，而是因为norm直接作用了loss函数，将loss函数变成了一个一阶、二阶均平滑的函数。

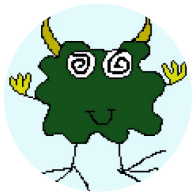

Dodo

6条评论

匿名 **发布于8:02 上午 - 1月 28, 2023**

To the pkudodo.com owner, Your posts are always well-formatted and easy to read.

()

回复

匿名 **发布于8:06 上午 - 9月 7, 2022**

()

bunadisisj nsjjsjsisjsmizjzjjzjzz zumzsert

回复

()

匿名 **发布于10:12 上午 - 11月 23, 2021**

e5x2fi

回复

()

匿名 **发布于10:42 上午 - 6月 15, 2020**

我记得，应该是normalization叭

回复

()

匿名 **发布于6:17 下午 - 10月 31, 2019**

可是，MIT的这个观点，也只是猜测啊，有什么证明吗?

回复

()

匿名 **发布于4:21 下午 - 1月 19, 2020**

看起来没有直接的证明，MIT通过对一阶、二阶导数的观察，发现观察结果是支持他们的假设的

回复

发表评论

内容(链接请去除http协议头，否则会被误判为垃圾评论)

设置显示昵称(选填)

发送信息

近期文章

- 论文|记忆网络之Memory Networks (http://www.pkudodo.com/2019/06/14/1-13/)
- 梳理|对话系统中的DST (http://www.pkudodo.com/2019/06/09/1-12/)
- 论文阅读|How Does Batch Normalizetion Help Optimization (http://www.pkudodo.com/2019/05/23/1-11/)
- 学习规划|机器学习和NLP入门规划 (http://www.pkudodo.com/2019/03/20/1-10/)
- 面试体会|微软、头条、滴滴、爱奇艺NLP面试感想 (http://www.pkudodo.com/2019/03/10/1-9/)

文章归档

- 2019年6月 (http://www.pkudodo.com/2019/06/)

- 2019年5月 (http://www.pkudodo.com/2019/05/)
- 2019年3月 (http://www.pkudodo.com/2019/03/)
- 2018年12月 (http://www.pkudodo.com/2018/12/)
- 2018年11月 (http://www.pkudodo.com/2018/11/)
- 2018年10月 (http://www.pkudodo.com/2018/10/)
- 2016年9月 (http://www.pkudodo.com/2016/09/)

标签

DST (http://www.pkudodo.com/tag/dst/)

K近邻 (http://www.pkudodo.com/tag/k%e8%bf%91%e9%82%bb/)

LSI (http://www.pkudodo.com/tag/lsi/)

memory network (http://www.pkudodo.com/tag/memory-network/)

MQTT (http://www.pkudodo.com/tag/mqtt/) NLP (http://www.pkudodo.com/tag/nlp/)

s3c2440 (http://www.pkudodo.com/tag/s3c2440/) SLU (http://www.pkudodo.com/tag/slu/)

SVM (http://www.pkudodo.com/tag/svm/) VSM (http://www.pkudodo.com/tag/vsm/)

体会 (http://www.pkudodo.com/tag/%e4%bd%93%e4%bc%9a/)

决策树 (http://www.pkudodo.com/tag/%e5%86%b3%e7%ad%96%e6%a0%91/)

分类器 (http://www.pkudodo.com/tag/%e5%88%86%e7%b1%bb%e5%99%a8/)

实现 (http://www.pkudodo.com/tag/%e5%ae%9e%e7%8e%b0/)

对话系统 (http://www.pkudodo.com/tag/%e5%af%b9%e8%af%9d%e7%b3%bb%e7%bb%9f/)

感想 (http://www.pkudodo.com/tag/%e6%84%9f%e6%83%b3/)

感知机 (http://www.pkudodo.com/tag/%e6%84%9f%e7%9f%a5%e6%9c%ba/)

支持向量机 (http://www.pkudodo.com/tag/%e6%94%af%e6%8c%81%e5%90%91%e9%87%8f%e6%9c%ba/)

文章相似度 (http://www.pkudodo.com/tag/%e6%96%87%e7%ab%a0%e7%9b%b8%e4%bc%bc%e5%ba%a6/)

最大熵 (http://www.pkudodo.com/tag/%e6%9c%80%e5%a4%a7%e7%86%b5/)

朴素贝叶斯 (http://www.pkudodo.com/tag/%e6%9c%b4%e7%b4%a0%e8%b4%9d%e5%8f%b6%e6%96%af/)

机器学习 (http://www.pkudodo.com/tag/%e6%9c%ba%e5%99%a8%e5%ad%a6%e4%b9%a0/)

爬虫 (http://www.pkudodo.com/tag/%e7%88%ac%e8%99%ab/)

统计学习方法 (http://www.pkudodo.com/tag/%e7%bb%9f%e8%ae%a1%e5%ad%a6%e4%b9%a0%e6%96%b9%e

统计方法学习 (http://www.pkudodo.com/tag/%e7%bb%9f%e8%ae%a1%e6%96%b9%e6%b3%95%e5%ad%a6%e

综述 (http://www.pkudodo.com/tag/%e7%bb%bc%e8%bf%b0/)

网易云歌单 (http://www.pkudodo.com/tag/%e7%bd%91%e6%98%93%e4%ba%91%e6%ad%8c%e5%8d%95/)

规划 (http://www.pkudodo.com/tag/%e8%a7%84%e5%88%92/)

详解 (http://www.pkudodo.com/tag/%e8%af%a6%e8%a7%a3/)

逻辑回归 (http://www.pkudodo.com/tag/%e9%80%bb%e8%be%91%e5%9b%9e%e5%bd%92/)

逻辑斯蒂回归 (http://www.pkudodo.com/tag/%e9%80%bb%e8%be%91%e6%96%af%e8%92%82%e5%9b%9e%e

面试 (http://www.pkudodo.com/tag/%e9%9d%a2%e8%af%95/)